

Patrones Invisibles

Información, Incertidumbre y Movilidad Urbana
Documento de soporte — Proyecto Retador

Consultoría analítica para UrbanMove: teoría de la información, clustering por partición y modelos de mezcla aplicados a 1,458,644 viajes de taxi en Nueva York (NYC Taxi Trip Duration, Kaggle), para responder dónde y cuándo posicionar conductores minimizando el tiempo de espera sin sobre-ofertar en zonas de baja demanda.

Integrantes y roles

Nombre completo	Código	Rol
Diego Alejandro Sandoval	339271	Rol 4 — Estratega de Negocio y Selección de Datos
Daniel Figueredo	332679	Rol 1 — Analista de Incertidumbre e Información
Juan Esteban Ocampo	286388	Rol 2 — Arquitecto de Segmentación por Partición
Juan Andres Martinez	326771	Rol 3 — Modelador de Mezclas y Variables Latentes

1. Contexto y pregunta de negocio

UrbanMove opera flotas de vehículos en Nueva York y necesita entender qué tan predecible es la demanda de viajes, qué perfiles de viaje existen realmente y dónde posicionar conductores para minimizar tiempos de espera sin sobre-ofertar en zonas de baja demanda. La pregunta madre que organiza el proyecto es:

¿Dónde y cuándo debe UrbanMove posicionar conductores para minimizar el tiempo de espera sin sobre-ofertar en zonas de baja demanda?

Los tres bloques técnicos la descomponen así: el Rol 1 mide **cuánta** incertidumbre hay sobre la demanda y cuánto la reduce conocer el momento; el Rol 2 identifica **dónde** están las zonas operativas reales y cuáles recogidas son atípicas; el Rol 3 determina **de qué tipo** es la demanda en cada zona y momento. El Rol 4 integra los tres resultados en recomendaciones operativas cuantificadas.

2. Dataset

Campo	Valor
Fuente	NYC Taxi Trip Duration — Kaggle
Enlace directo	https://www.kaggle.com/c/nyc-taxi-trip-duration/data
Archivo usado	train.csv (test.csv no incluye la variable trip_duration)
Tamaño original	1,458,644 viajes · enero-junio de 2016 · 11 columnas
Licencia	Uso académico/competencia (Kaggle)

3. Metodología: limpieza y estrategia de muestreo

3.1 Justificación (máx. 200 palabras)

Usamos train.csv de Kaggle: 1,458,644 viajes de enero a junio de 2016. Primero eliminamos solo errores de medición físicamente imposibles: coordenadas fuera de Nueva York, pasajeros inválidos, duraciones menores a 60 segundos o mayores a 3 horas, desplazamientos menores a 100 metros y velocidades superiores a 100 km/h. Quedaron 1,438,943 viajes (-1.35%). Los días atípicos reales (23-24 de enero y 30 de mayo de 2016) se conservaron y marcaron deliberadamente, porque son demanda real y no errores de medición.

Sobre esa población extrajimos una muestra estratificada proporcional por día de la semana x hora (168 estratos): 50,004 viajes, semilla 42. Muestreamos por el costo de los Roles 2 y 3: el índice de silueta crece cuadráticamente (19.7 s con 50,000 viajes; 78.3 s con 100,000). Estratificar reproduce exactamente la distribución temporal, eje del análisis de información.

Verificamos la representatividad con divergencia KL entre muestra y población: 0.00000 bits en hora y día, 0.00667 bits en zona y 0.00042 bits en duración; las zonas presentes cubren el 99.85% de la demanda. Descartamos filtrar un solo mes: distorsiona el día de la semana (KL entre 0.0042 y 0.0098 bits) sin reducir el error espacial.

186 palabras.

3.2 Criterios de limpieza aplicados

Criterio	Regla	Elimina
C1 — Zona geográfica	Recogida y destino dentro de NYC (lon -74.3/-73.7, lat 40.5/40.9)	1,698
C2 — Pasajeros	Entre 1 y 6 pasajeros	65
C3 — Duración	Entre 60 s y 3 horas	10,707
C4 — Distancia mínima	Distancia Haversine ≥ 0.1 km	13,318
C5 — Velocidad	Velocidad promedio ≤ 100 km/h	175

Total eliminado: 19,701 registros (1.351%). El 99.8% de los viajes de más de 22 horas (defecto de registro, velocidad mediana 0.097 km/h) corresponde a un único proveedor (vendedor_id=2), que solo representa el 53.5% de los viajes totales. La limpieza altera la curva horaria de demanda en un máximo de 0.014 puntos porcentuales, y su tasa varía de 1.15% (9h) a 2.63% (4h) — un sesgo medido y reportado, no ignorado.

3.3 Días atípicos conservados

El 23-24 de enero y el 30 de mayo de 2016 (10,436 viajes; 0.725% del dataset limpio) se conservan deliberadamente y se marcan con una variable indicadora, por coherencia con el principio de limpieza: se eliminan errores de medición, no eventos reales. Estos días corresponden a un evento meteorológico extremo (verificar fuente externa) y a un feriado (Memorial Day), respectivamente — no a fallas del sistema de registro.

4. Resultados — Rol 1: Teoría de la información

Todos los valores en bits (log base 2). Cifras calculadas sobre la **población limpia** (1,438,943 viajes) para evitar el sesgo de estimación detectado en la muestra (ver Nota metodológica).

Concepto	Resultado	Interpretación
Entropía H(zona recogida)	5.466 bits (≈ 44 zonas efectivas de 242)	La demanda se comporta como repartida en solo 44 zonas
Entropía H(zona destino)	6.035 bits (≈ 65 zonas efectivas de 553)	Los destinos están más dispersos que los orígenes
Entropía condicional H(zona hora)	5.385 bits (recogida) - 5.920 (destino)	Conocer la hora reduce poco la incertidumbre espacial
Información mutua I(hora; zona recogida)	0.0813 bits (1.49% de H)	La hora casi no cambia dónde ocurre la demanda
Información mutua I(hora; zona destino)	0.1144 bits (1.90% de H)	Validado: $p < 0.005$ (prueba de permutación, 200 iter.)
Divergencia KL(fin de laboral) en hora	0.1815 bits	El fin de semana difiere sobre todo en horario

Concepto	Resultado	Interpretación
Divergencia KL(finde laboral) en zona	0.0549 bits	El mapa espacial cambia poco entre laboral y finde
Entropía cruzada (aplicar modelo laboral al finde)	+4.06% en hora · +0.99% en zona	Costo de no separar el plan horario de fin de semana
Jensen — concavidad de H	$H(Z) - H(Z hora) = I(hora; zona)$ exacto	Explica por qué la información mutua nunca es negativa
Jensen — sesgo del promedio en log	Duración: 29.1% · Distancia: 50.0%	La media geométrica subestima el promedio real
Log-sum-exp — clasificación de 182 días	97.80% de acierto (178/182) vs. 71.43% base	Detecta festivos (Año Nuevo, Memorial Day) sin etiquetarlos

Nota metodológica: la información mutua estimada por conteo tiene sesgo positivo conocido. Se midió empíricamente con una prueba de permutación (200 iteraciones): en la muestra de 50,004 viajes, el 54% de $I(hora; zona destino)$ resultó ser sesgo estadístico puro (observado 0.2167 bits; promedio bajo permutación 0.1177 bits). Por eso las cifras oficiales de este bloque usan la población completa, donde el sesgo es despreciable.

5. Resultados — Rol 2: Clustering por partición

Espacio de trabajo: coordenadas de recogida proyectadas a kilómetros (px, py), sin escalar. Muestra: 50,004 viajes.

5.1 K-means — selección de K

K	Silueta	Davies-Bouldin	Estabilidad (ARI mín.)	Observación
2	0.809	0.178	1.000	Descartado: solo separa JFK (2.21%) del resto
4	0.492	0.502	0.997	Mejor silueta
5	0.452	0.561	0.996	Codo de la curva de inercia; SELECCIONADO
9	0.416	0.692	0.523	Descartado: no reproducible entre semillas

K=5 (seleccionado): KM0 Midtown 44.08% · KM1 Downtown 27.58% · KM2 Upper Manhattan 23.11% · KM3 LaGuardia 3.06% · KM4 JFK 2.17%. Radios medianos en Manhattan: 1.10-1.41 km (coherente con la escala operativa de zona de 1 km).

5.2 DBSCAN — tratamiento del ruido

Parámetro	Valor	Justificación
min_samples	20 (≈3.2 recogidas reales/día en el radio)	10 produce micro-clusters de 7 viajes; 50 es demasiado estricto
Epsilon (ε)	418 metros	Rodilla de la gráfica k-distancia (percentil 98.4)
Clusters encontrados	10	Incluye ambos aeropuertos como hubs aislados
Ruido	1.034% (517 viajes ≈ 82 recogidas reales/día)	Robusto: 0.67%-1.92% para ε entre 300 y 600 m

Comparación de métodos: ARI entre K-means y DBSCAN = 0.100 (particiones casi opuestas, por diseño: K-means reparte toda la ciudad, DBSCAN separa masa densa de ruido). DBSCAN revela que Manhattan es un continuo de densidad (92.30% de las recogidas en un solo cluster) — las zonas de K-means son cortes operativos, no fronteras naturales. **Tratamiento del ruido:** no pre-posicionar flota fija; despacho bajo demanda (una recogida cada 37.9 horas por punto de ruido).

6. Resultados — Rol 3: Mezclas gaussianas y variables latentes

Espacio: (log distancia, log duración), covarianza completa. Criterio de convergencia: variación en la log-verosimilitud media menor a $1e-9$ entre iteraciones del algoritmo EM (implementado manualmente en NumPy y verificado contra scikit-learn).

6.1 Selección de K (criterio BIC, tolerancia estricta)

K	BIC	Observación
4	179,550.6	
5	179,390.0	SELECCIONADO: mismo óptimo desde 10 inicializaciones distintas

K	BIC	Observación
6	179,315.7 / 179,430.2	No reproducible: dos semillas dan dos soluciones distintas (mínimos locales reales)
7	179,472.3	El BIC empeora

6.2 Parámetros finales y perfiles de viaje

Perfil	Peso (π)	Distancia típica	Duración típica	Velocidad	Rasgo distintivo
P0 — Corto lento	0.0280	0.63 km	7.2 min	5.3 km/h	Posible congestión/GPS impreciso
P1 — Corto urbano	0.4206	1.29 km	7.0 min	11.0 km/h	El más frecuente (42.1%)
P2 — Medio urbano	0.4046	2.78 km	12.7 min	13.1 km/h	Se solapa con P1 (frontera difusa)
P3 — Largo interdistrital	0.1285	8.09 km	24.2 min	20.0 km/h	19.8% de madrugada (base 11.7%)
P4 — Ruta aeropuerto (JFK)	0.0183	20.49 km	44.7 min	27.5 km/h	Distancia casi fija ($\pm 5\%$); certeza 0.867

Iteraciones hasta convergencia (K=5, semilla 42): 1,395 iteraciones con inicialización k-means++ (rango 1,266-2,947 en 5 semillas) vs. 4,456 con inicialización aleatoria (rango 4,345-4,780 en 5 semillas). Ambas inicializaciones convergen al mismo óptimo global (log-verosimilitud media = -1.790619), confirmado por implementación manual del EM. La log-verosimilitud es monótona creciente en el 100% de las iteraciones de ambas corridas, como garantiza la teoría del algoritmo.

Responsabilidades (incertidumbre de la asignación): responsabilidad máxima mediana = 0.754; 18.19% de los viajes son ambiguos (responsabilidad máxima < 0.6), concentrados en Manhattan (18-19% ambiguos) frente a los aeropuertos (5.5-6.9% ambiguos).

7. Integración — Rol 4

La integración aplica herramientas del Rol 1 (entropía, información mutua, divergencia KL) directamente sobre las salidas del Rol 2 (zonas) y el Rol 3 (perfiles de viaje) — resultados que ningún bloque puede producir por sí solo.

Pregunta de integración	Resultado cuantificado
¿Qué explica mejor el tipo de viaje: zona u hora?	$I(\text{zona}; \text{tipo}) = 0.139$ bits (8.69%) vs. $I(\text{hora}; \text{tipo}) = 0.020$ bits (1.24%) — la zona explica 7x más
¿El fin de semana cambia el tipo de viaje?	$KL(\text{finde} \parallel \text{laboral})$ en tipo = 0.0020 bits, 91 veces menor que en hora (0.1815 bits)
¿Qué es el ruido de DBSCAN en términos de tipo de viaje?	1.79x más propenso a ser viaje largo (P3) y 1.91x más a ser de aeropuerto (P4) que lo normal
¿Qué franja es más incierta en las 3 dimensiones a la vez?	Madrugada (0-5h): ≈ 52 zonas efectivas (R1) · 2.87% de ruido vs 0.79% resto (R2) · 20.1% viajes largos (R3)
¿JFK y LaGuardia son operativamente iguales?	JFK: 54.9% ruta propia, certeza 0.867, ruido 5.07%. LaGuardia: 68.4% genérico largo, ruido 10.31% (2x)

8. Recomendaciones operativas cuantificadas

1. Posicionamiento por zona, no por hora

La zona de origen explica el tipo de viaje 7 veces mejor que la hora del día ($I=0.139$ vs. 0.020 bits). Dimensionar la flota base por zona en proporciones fijas (Midtown 3,485 viajes/día · Downtown 2,180 · Upper Manhattan 1,827 · LaGuardia 242 · JFK 172) y usar la hora solo para escalar el volumen total, no para redistribuir la mezcla entre zonas.

2. Un solo mapa, dos calendarios de turnos

El fin de semana casi no cambia el tipo de viaje ($KL=0.0020$ bits) pero sí la hora ($KL=0.1815$ bits, 91x mayor). Mantener el mismo mapa de zonas todos los días, pero operar con calendarios de turnos distintos para días laborales y para fin de semana/festivos — el clasificador de log-sum-exp (97.80% de acierto) permite identificar automáticamente los festivos por su patrón horario.

3. Madrugada: despacho bajo demanda, no posicionamiento fijo

De 0h a 5h la demanda es simultáneamente la más dispersa espacialmente (≈ 52 zonas efectivas), la más ruidosa en el clustering (2.87% vs. 0.79% el resto) y la más propensa a viajes largos (20.1% vs. $\sim 12\%$). Sustituir el posicionamiento fijo por despacho bajo demanda con radio ampliado y recargo dinámico que compense el desplazamiento extra.

4. Tratar JFK y LaGuardia de forma distinta

JFK tiene una ruta con identidad propia y predecible (54.9% en un solo perfil, certeza 0.867, ruido 5.07%); LaGuardia es demanda de viaje largo genérico y más ruidosa (68.4% en el perfil compartido, ruido 10.31%, el doble). Mantener/crear carril dedicado en JFK; en LaGuardia, cubrir con la misma capacidad flexible de viajes largos del resto de la ciudad, sin sobre-invertir en infraestructura fija.

9. Limitaciones y siguientes pasos

Los resultados son asociaciones estadísticas sobre un dataset histórico de un solo semestre (enero-junio 2016), no evidencia causal ni validación en operación real. Los nombres de zonas fuera de Manhattan (hubs identificados por DBSCAN) están pendientes de verificación cartográfica. La atribución del 23 de enero a un evento meteorológico requiere confirmación con fuente externa antes de citarse como causa. Como siguiente paso, se recomienda validar las recomendaciones con datos operativos reales de UrbanMove antes de implementarlas.

10. Repositorio GitHub

[ENLACE GITHUB PENDIENTE — completar en la Etapa 14, antes del domingo 27 a las 11:00 p.m.]